04 · 考核评价与评分量表

> 课程：AI 智能体工程化项目实战 | 版本 v1.0 评价理念：以工件为证据，以标准为准绳，以能力为目标。不考"记住了什么"，考"做出来了什么、能不能被验证、能不能被交接"。

1. 成绩构成

类别	项目	占比	评价人	评价时点
过程性 60%	工件作品集（16 项）	35%	教师 + 助教	每讲
	团队协作与职业素养	10%	互评 40% + 教师 40% + 企业 20%	期中、期末
	阶段评审（3 次）	15%	评审组（含企业）	第 4/9/14 讲
终结性 40%	交付物验收（42 项）	25%	评委组	第 16 讲
	答辩	15%	评委组（5 人）	第 16 讲
合计		100%		

1.1 及格与优秀

等级	条件
不及格	总分 < 60，或 42 项通过率 < 70%，或触发一票否决
及格	总分 ≥ 60 且通过率 ≥ 70%
良好	总分 ≥ 75 且通过率 ≥ 80%
优秀	总分 ≥ 90 且通过率 ≥ 90%，且有 ≥1 项"标杆工件"

1.2 一票否决（直接不及格）

- 向 PLC/DCS/SIS 下发任何控制指令（含模拟环境中的真实协议报文）。
- 伪造测试结果、伪造运行截图、篡改验收记录。
- 隐瞒已知的严重缺陷（导致数据丢失、越权、误停机）。
- 将企业真实生产数据、设备编号、工艺参数带出教学环境。
- 抄袭他组交付物且拒不改正。

2. 工件作品集评分（35%）

2.1 16 讲工件与分值

讲次	工件	分值	核心判据
01	团队章程 + 角色卡 + 看板	1.5	角色清晰、规约可执行
02	需求规格 v1.0 + RTM	3.0	可判定、可追溯
03	C4 图 + 领域事件清单	3.0	边界合理、事件规范
04	HI 实验报告	3.0	计算正确、降级正确
05	工具注册表 + 分级表	3.0	粒度合理、副作用准确

讲次	工件	分值	核心判据
06	状态机 + trace + 故障注入记录	3.0	状态完整、可回放
07	权限矩阵 + 攻击测试报告	4.0	拦截率 100%、误拦截 ≤10%
08	MCP manifest + 调用记录	3.0	协议正确、防护到位
09	技能全链路记录	3.0	审批红线不可绕过
10	诊断报告 + 判据发布单	3.5	证据完整、版本规范
11	反事实报告	3.0	带区间、null 条件正确
12	方案卡 + 会诊记录	3.5	独立出意见、成本算对
13	用例集 + 缺陷报告	3.0	可复现、分层合理
14	部署单 + 联邦联调记录	3.0	可重启恢复、断网可用
15	治理看板 + 演练记录	2.5	可下钻、版本可追溯
16	交付包 + 答辩 PPT + 复盘	3.0	证据齐全、复盘具体
合计		48.0	折算为 35%（×0.729）

> 折算说明：工件原始分 48 分，按 35/48 ≈ 0.729 折算计入总评。缺交按 0 计；逾期 48 小时内 ×0.8；超过 1 周不计分。

2.2 单个工件的评分维度（通用）

维度	权重	优秀（4）	良好（3）	合格（2）	待改进（1）
完整性	25%	要求项全部具备，另有增值内容	要求项齐全	缺 1 – 2 项非关键项	缺关键项
正确性	35%	无错误，边界处理到位	主体正确，个别瑕疵	有明显错误但可修	结论错误
可验证性	25%	他人可独立复现/复核	按说明可复现	需原作者解释	无法验证
规范性	15%	命名/格式/版本完全规范	基本规范	部分不规范	混乱

---

3. 六维能力评分量表（用于阶段评审与答辩）

> 4 级：A 优秀（90 – 100）｜B 良好（75 – 89）｜C 合格（60 – 74）｜D 待改进（<60） 布鲁姆对齐：需求与规格 = 理解/应用；架构与设计 = 分析；实现与工具 = 应用；测试与质量 = 分析/评价；安全与合规 = 评价；协作与表达 = 费曼输出。证据达不到该层级的，最高只能给 B。

维度 1 · 需求与规格

等级	行为描述
A	需求可判定、可追溯；能识别隐含需求与冲突；变更有控制
B	需求基本可判定；RTM 完整；少量表述模糊
C	有需求文档，但部分条目不可判定
D	需求缺失或无法验收

维度 2 · 架构与设计

等级	行为描述
A	边界清晰、职责单一；同步/异步选择有理由；能说明"不做什么"
B	结构合理；个别边界模糊
C	能画出结构，但分层混乱
D	无设计或设计无法支撑需求

维度 3 · 实现与工具

等级	行为描述
A	工具粒度合理、副作用准确、失败可处理；代码可读、注释解释"为什么"
B	功能正确；部分异常未处理
C	能跑通主流程；边界处理不足
D	无法运行或大量硬编码

维度 4 · 测试与质量

等级	行为描述
A	三层测试齐备；能定位根因；缺陷可被他人复现；有回归
B	有测试且覆盖主要路径；缺陷描述清楚
C	测试较少，仅覆盖正常路径
D	无测试或测试造假

维度 5 · 安全与合规

等级	行为描述
A	权限门完整；注入防御有效；红线有代码级保障；数据分级清晰
B	主要写操作有确认；防御基本有效
C	有安全意识但实现不完整
D	存在越权/注入/数据外泄风险

维度 6 · 协作与表达

等级	行为描述
A	分工明确、交接顺畅；8 分钟讲清问题—方案—证据—价值；能回答追问
B	协作正常；表达清楚但重点不够突出
C	基本完成分工；表达依赖念稿
D	协作混乱或无法讲清自己的工作

4. 阶段评审（15%）

4.1 三次评审安排

评审	时点	对象	形式	分值
R1 规格基线	第 4 讲末	需求规格 v1.0 + C4 + HI 报告	评审会（企业导师参加）	5%
R2 内核打通	第 9 讲末	工具 + 循环 + 权限 + MCP + 记忆	演示 + 代码走查	5%
R3 交付预检	第 14 讲末	部署 + 测试 + 治理	现场演练	5%

4.2 评审评分表

项	权重	说明
工件齐备性	20%	该阶段应有工件是否齐全
演示通过	30%	现场演示是否一次跑通（允许 1 次重试）
代码/文档质量	25%	走查抽 3 个文件
答辩应对	15%	能否回答"为什么这么做"
改进闭环	10%	上次评审意见是否落实

评审结论：通过 / 有条件通过（限期整改）/ 不通过（重做）。
"有条件通过"需在下一讲开课前提交整改证据，否则该项计 0。

---

5. 42 项交付验收清单（25%）

> 六大类，共 42 项。每项判定： 通过 | ⚠ 部分通过（计 0.5） | 未通过。通过率 = （ 数 + 0.5×⚠ 数）/ 42。

A. 功能完整性（10 项）

#	验收项	证据要求
A1	设备档案可查询（列表/详情/测点）	接口响应 + 截图
A2	健康指数可计算，返回五维分解	响应 JSON 含 contributions
A3	诊断结论含证据链（测点/时间窗/特征值/版本）	一条完整响应
A4	告警可产生、可确认、可关闭，且有关闭权限控制	操作日志
A5	方案卡可生成，含结论/窗口/备件/成本	卡片数据
A6	方案卡需人工确认后生效	确认记录（含确认人）
A7	工单可从方案卡生成并回写状态	工单状态流转记录
A8	知识库可检索，返回相关案例	检索结果
A9	趋势数据可按设备/时间窗查询	趋势接口响应

#	验收项	证据要求
A10	多租户数据隔离（跨租户查询返回空/403）	越权测试记录

B. 性能与容量（5 项）

#	验收项	证据要求
B1	单设备诊断 P95 ≤ 800ms（缓存命中 ≤ 100ms）	压测报告
B2	列表接口 P95 ≤ 500ms（1000 条数据）	压测报告
B3	并发 50 请求无错误（错误率 < 1%）	压测报告
B4	缓存命中率 ≥ 60%（稳态）	缓存统计
B5	单次智能体循环成本 ≤ ¥0.8（或 token ≤ 60k）	trace 统计

C. 安全与合规（8 项）

#	验收项	证据要求
C1	所有写操作经权限门（ask），无直连写接口	代码走查 + 日志
C2	金额 > ¥50,000 触发双人复核	测试记录
C3	确认令牌不可由模型生成	攻击测试
C4	四类提示注入全部被拦截	攻击报告
C5	工具白名单生效，未注册工具不可调用	测试记录
C6	SSRF 防护有效（内网/跳转/重绑定）	测试记录
C7	审计日志含 who/when/what/result/trace_id	日志样例
C8	无向 PLC/DCS 下发的代码路径	代码检索 + 声明

D. 可靠性与降级（7 项）

#	验收项	证据要求
D1	数据缺失时返回 `degraded=true` 且说明缺哪维	测试记录
D2	数据不足时拒绝给结论（不返回"正常"）	测试记录
D3	智能体循环有 max_turns/wall_time 熔断	故障注入记录
D4	熔断后转人工（ESCALATE），不静默失败	trace
D5	边缘断网时本地诊断可用	断网演练记录
D6	恢复后数据补传且不重复	联调记录
D7	服务重启后数据不丢（持久化验证）	重启前后对比

E. 可运维性（6 项）

#	验收项	证据要求
E1	健康检查接口返回依赖状态	/healthz 响应
E2	一键部署脚本可用，含回滚步骤	脚本 + 演练
E3	关键配置外置（环境变量/ConfigMap）	配置清单
E4	日志分级、可检索	日志样例
E5	trace 可下钻到工具级	trace 截图
E6	模型/判据版本可查、可回滚	版本表 + 回滚记录

F. 文档与交接（6 项）

#	验收项	证据要求
F1	README 可在 10 分钟内完成本地启动	按文档实操录像/记录
F2	接口文档与实现一致（抽 3 个接口核对）	核对记录
F3	部署文档含前置条件、步骤、验证、回滚	文档
F4	运维手册含 5 个常见故障处置	文档
F5	交付清单与证据索引完整	索引表
F6	免责声明与 AI 生成内容标识	界面/文档

---

6. 答辩评分（15%）

6.1 答辩流程（每组 15 分钟）

环节	时长	要求
陈述	8 ′	背景 1 ′ / 方案 3 ′ / 证据 2 ′ / 价值 1 ′ / 反思 1 ′
问答	7 ′	评委 3 – 5 问，组内任何人可答

6.2 评分表（5 位评委独立打分，去掉最高最低取平均）

维度	权重	A（90 – 100）	B（75 – 89）	C（60 – 74）	D（<60）
问题定义	15%	问题真实、边界清楚、有数据支撑	问题清楚	问题较模糊	没有问题
方案合理性	25%	选型有约束依据，有权衡分析	方案可行	方案勉强可用	方案不成立
证据充分性	30%	每项结论都有可核验证据	主要结论有证据	证据零散	无证据
业务价值	15%	能量化收益（停机/工时/成本）	能说清价值	价值模糊	讲不出价值

维度	权重	A（90 – 100）	B（75 – 89）	C（60 – 74）	D（<60）
表达与应对	15%	逻辑清晰、答问准确、不回避	表达清楚	依赖念稿	答非所问

6.3 评委常问 10 题（附回答要点）

- "你怎么证明这个结论是对的？" → 证据链 + 测试 + 复现步骤。
- "如果模型给出错误建议，会造成什么后果？" → 权限门 + 人工确认 + 免责声明。
- "这套东西上线后，谁维护？怎么维护？" → 运维手册 + 监控 + 回滚。
- "为什么选这个技术，不选那个？" → 约束（资源/断网/成本/团队）+ 权衡。
- "数据不出厂，你怎么做到总部能看到？" → 摘要上行 + 分级。
- "误报怎么控制？" → 多阶谐波 + SNR + 阈值标定 + 反馈闭环。
- "系统崩了怎么办？" → 降级路径 + 熔断 + 告警 + 恢复步骤。
- "你的测试覆盖了什么，没覆盖什么？" → 分层说明 + 已知缺口。
- "这套方案能复制到别的基地吗？" → 参数化 + 部署脚本 + 判据版本。
- "如果只给你一半时间，你会砍掉什么？" → 优先级判断（MoSCoW）。

---

7. 团队协作与职业素养（10%）

7.1 评价构成

来源	权重	评价内容
组内互评	40%	贡献度、协作、可靠性（匿名）
教师观察	40%	出勤、参与、提问质量、守时
企业导师	20%	职业规范、沟通、现场适配

7.2 组内互评表（每人给其他成员打分，1 – 5 分）

维度	说明
任务贡献	是否按时完成自己那份
协作支持	是否主动帮助他人、共享信息
交付质量	交付物是否可直接使用
沟通反馈	是否及时沟通风险与阻塞

> 互评结果偏差过大（某人被评 < 2 分且多人一致）时，教师需面谈核实。

---

8. 达成度分析与持续改进

8.1 课程目标达成度

指标	计算方式	目标值
CO 达成度	对应工件/考核项平均分 / 满分	≥ 0.75
SO 达成度	素养评分项平均分 / 满分	≥ 0.80

指标	计算方式	目标值
验收通过率	42 项加权通过率	≥ 0.85（班级均值）
优秀率	总分 ≥ 90 的比例	15% – 30%
认知层级达成度	各讲主层级对应评分项均分 / 满分	≥ 0.70
费曼通过率	当讲费曼时刻通过人次 / 参与人次	≥ 0.75

8.2 改进闭环

- 每轮结束，计算各 CO 达成度，< 0.65 的进入改进清单。
- 改进措施必须具体到"讲次 + 教学活动 + 资源"，不接受"加强辅导"这类表述。
- 改进结果写入 `12_■■■■`（本文件 §8.3）并在下一轮验证。

8.3 改进记录（模板）

轮次	问题	证据	措施	验证结果
2026 秋	示例：第 11 讲区间估计掌握差	CO10 达成度 0.58	增加 1 组"过窄区间"反例 + 10 分钟手算	待验证

---

9. 附：成绩登记表模板

学号	姓名	组别	工件(35)	协作(10)	评审(15)	验收(25)	答辩(15)	总分	等级	备注

> 备注栏记录：一票否决、缓交、补考、标杆工件等。